

## **Modelos de crescimento em experimentos com tratamentos: uma abordagem com modelos mistos**

**Alessandro Dal'Col Lúcio<sup>1</sup>, Bruno Giacomini Sari<sup>2</sup>, Maria Inês Diel<sup>2</sup>, Tiago Olivoto<sup>2</sup>, Patrícia Jesus de Melo<sup>2</sup>, Dionatan Ketzer Krysczun<sup>2</sup>.**

### **1 Introdução**

A utilização de modelos de crescimento para avaliar experimentos de olerícolas de múltiplas colheitas tem sido crescente. Os modelos de crescimento tem sido uma alternativa para contornar problemas recorrentes neste tipo de experimento quando se utiliza a ANOVA, tais como não normalidade e heterocedasticidade dos resíduos (Sari et al., 2018, 2019a, 2019b). Além de contornar estes problemas, os modelos de crescimento também possuem parâmetros com interpretação biológica, o que aumenta as inferências sobre o comportamento produtivo destas culturas ao longo do tempo (Diel, 2019; Sari et al., 2018, 2019a, 2019b).

Em experimentos com tratamentos é interessante verificar se estes possuem algum efeito sobre os parâmetros dos modelos. Utilizando modelos não lineares mistos é possível determinar o efeito dos tratamentos sobre os parâmetros verificando se a variação dos efeitos aleatórios das parcelas (consideradas a priori) está associada a alguma covariável adicionada ao modelo (Pinheiro & Bates, 2000). Esta abordagem não apenas permite comparar tratamentos, mas também as suas interações quando há mais de um fator em estudo.

Adicionar os tratamentos como covariáveis pode ser uma alternativa para testar os seus efeitos sobre os parâmetros do modelo. Portanto, o presente trabalho tem como objetivo verificar o efeito de diferentes tratamentos sobre a produção de tomateiro utilizando uma abordagem com modelos não lineares mistos.

### **2 Material e Métodos**

Dois experimentos foram conduzidos no Departamento de Fitotecnia da Universidade Federal de Santa Maria (UFSM), Santa Maria, RS. Os experimentos foram realizados na estação primavera-verão de 16/08/2010 a 27/01/2011, um a campo e outro em túnel baixo. Em ambos os experimentos foram semeadas três linhas com mudas que possuíam quatro folhas verdadeiras no momento do transplante. As mudas foram semeadas com espaçamento 0,8 m entre si, totalizando 24 plantas por linha. As fileiras de cultivo estavam espaçadas 1,2 m entre si.

As parcelas eram constituídas de duas plantas na fileira de cultivo. Os tratamentos testados foram constituídos por misturas de adubação mineral e um bioproduto oriundo da fermentação alcoólica da batata (Acrescent Solus®): (T1) adubação mineral em cobertura (sem Acrescent

---

<sup>1</sup> Universidade Federal de Santa Maria, Departamento de Fitotecnia, Centro de Ciências Rurais. email: adlucio@ufsm.br

<sup>2</sup> Universidade Federal de Santa Maria, Programa de Pós-Graduação em Agronomia. email: brunosari@hotmail.com, mariaines.diel@hotmail.com, tiagoolivoto@gmail.com, patty\_de\_melo@yahoo.com.br, diona1994@hotmail.com

Solus®); (T2) adubação mineral em cobertura mais 50 L ha<sup>-1</sup> de Acrescent Solus® aplicados aos 30 e 60 dias após o transplante; (T3) adubação mineral em cobertura mais 0,5 L ha<sup>-1</sup> de Acrescent Solus® aplicados após todas as colheitas.

Foram realizadas 10 colheitas, aos 87, 109, 114, 121, 127, 135, 141, 149, 158 e 164 dias após o transplante (DAT). Os frutos colhidos foram pesados e o peso médio de frutos por planta foi calculado para cada parcela. Os valores do peso médio de frutos por planta foram acumulados em cada colheita (C) da seguinte forma: C1 (produção acumulada aos 87 DAT), C1+C2 (produção acumulada aos 109 DAT), ..., C1+C2+C3+...+C10 (produção acumulada aos 164 DAT).

O modelo logístico foi ajustado aos dados de produção acumulada ao longo do tempo. A parametrização utilizada do modelo logístico foi:

$$Y_i = \frac{\beta_1}{1 + \exp(\beta_2 - \beta_3 \times \text{DAT})} + \varepsilon_i, \text{ onde } \beta_1 \text{ corresponde a assíntota, } \beta_2 \text{ é}$$

um parâmetro de escala associado a maturidade das plantas no início das colheitas e  $\beta_3$  é a taxa de produção de frutos. Um modelo inicial (reduzido), considerando o efeito aleatório das parcelas em todos os parâmetros, foi ajustado. O modelo logístico relacionando a produção de cada parcela em função dos dias após o transplante é:

$$Y_{ij} = \frac{\beta_{1i}}{1 + \exp(\beta_{2i} - \beta_{3i} \times \text{DAT})} + \varepsilon_{ij},$$

$$\beta_i = \begin{bmatrix} \beta_{1i} \\ \beta_{2i} \\ \beta_{3i} \end{bmatrix} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \hat{\beta}_3 \end{bmatrix} + \begin{bmatrix} b_{1i} \\ b_{2i} \\ b_{3i} \end{bmatrix} = \hat{\beta} + b_i$$

onde as estimativas  $\hat{\beta}$  representam a média populacional dos parâmetros  $\beta$  do modelo (parte fixa), e  $b$  representam o desvio entre a estimativa  $\hat{\beta}$  e o parâmetro  $\beta$ . O efeito aleatório dos parâmetros deve ser independente para as diferentes parcelas. Por fim, os efeitos aleatórios foram estimados e um gráfico de valores preditos vs covariáveis candidatas foi gerado. Este gráfico foi utilizado para identificar a influência das covariáveis nos parâmetros do modelo.

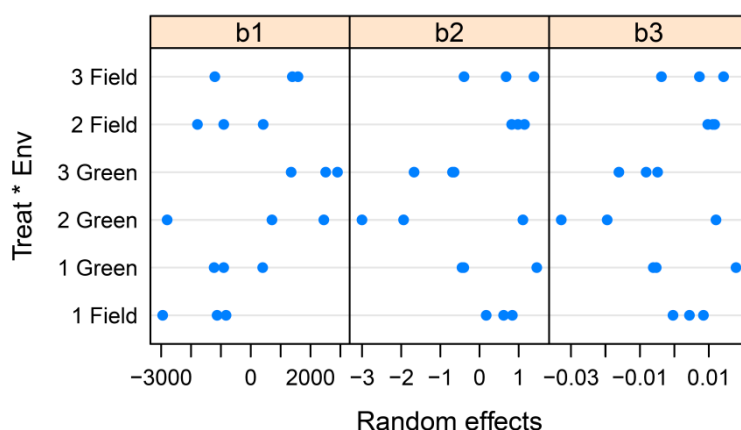
Posteriormente, covariáveis foram adicionadas ao modelo (completo), que no nosso caso foram os tratamentos testados. Desta forma, os parâmetros do modelo passaram a ser representados por (usando  $\beta_1$  como exemplo):  $\beta_1 = \hat{\beta}_1 + \gamma_1 x_{1i} + \gamma_2 x_{2i} + \gamma_3 x_{1i} x_{2i} + b_{1i}$ , onde  $\hat{\beta}_1$  é a média da assíntota,  $\gamma_1$  e  $\gamma_2$  representa o efeito principal da adubação e do ambiente, respectivamente; e  $\gamma_3$  mede o efeito da interação entre a adubação e o ambiente. Por fim, assim como ocorreu no modelo reduzido, os efeitos aleatórios foram preditos e um gráfico de valores preditos vs covariáveis candidatas foi gerado.

As hipóteses sobre o efeito fixo de adubação, ambiente e interação adubação vs ambiente foram realizadas utilizando o teste F. Para verificar onde as resposta das covariáveis é mais acentuada (em relação aos parâmetros), foram realizados testes de razão de verossimilhança (TRV). Nestes testes foi retirado o efeito aleatório dos parâmetros individualmente, gerando três modelos reduzidos que foram testados contra um modelo completo (com todos os efeitos aleatórios). As análises foram realizadas no software R (R Core Team, 2018).

### 3 Resultados e discussão

Não houve problema de convergência do modelo em relação aos dados acumulados de massa médio de frutos por planta. O modelo logístico já vem sendo utilizado para modelar a produção de diversas espécies olerícolas ao longo do tempo (Lúcio et al., 2015, 2016a, 2016b; Sari et al., 2018, 2019a, 2019b; Diel et al., 2019) sem problemas de convergência. Sari et al. (2018, 2019a, 2019b) verificaram, para as culturas da berinjela e tomate, que a parametrização do logístico testado neste trabalho se mostrou adequado pois possui parâmetros próximos de ser não viesados, uma vez que possuem baixa não linearidade intrínseca e paramétrica. Consequentemente, relatam os autores, os parâmetros descrevem o comportamento produtivo de forma fidedigna.

O modelo inicial, considerando o efeito aleatório das parcelas em todos os parâmetros, cumpriu os pressupostos do modelo: normalidade, homocedasticidade e independência dos resíduos. O gráfico dos efeitos aleatórios vs covariáveis, que no nosso caso são os tratamentos, mostrou que estes tiveram efeitos sobre os parâmetros. Como os efeitos aleatórios devem ter média zero e ser independentes em relação às parcelas, os desvios sistemáticos mostram que há influência da adubação e do ambiente sobre os parâmetros (Figura 1).



**Figura 1** - Estimativa dos efeitos aleatórios por ambiente e tratamento no modelo logístico reduzido. 1 = T1; 2 = T2; 3 = T3; Green = Túnel baixo; Field = Campo.

O parâmetro  $\beta_1$  tende a ter desvios positivos em T3 e negativos em T2. Também se observa que nos experimentos conduzidos a campo destes parâmetros tendem a ser positivos, enquanto que nos experimentos túneis eles são negativos. Nos experimentos conduzidos a campo os valores dos parâmetros  $\beta_2$  e  $\beta_3$  tendem a serem maiores do que os observados nos túneis (Figura 1). O teste F pode ser utilizado para confirmar o comportamento visual dos gráficos de efeitos aleatórios vs covariáveis. Percebe-se um efeito significativo do ambiente e dos tratamentos sobre o parâmetro  $\beta_1$ , porém não há interação entre os fatores. Em relação aos demais parâmetros, observa-se que apenas o efeito de ambiente é significativo (Tabela 1). Percebe-se claramente que, de alguma forma, a adubação e o ambiente interferem no comportamento produtivo do tomateiro.

**Tabela 1** – Teste F condicional para as covariáveis adicionadas nos efeitos fixos do modelo logístico.

Parâmetros	numDF <sup>1</sup>	denDF	F calculado	p-valor
<hr/> $\beta_1$ <hr/>				
Ambiente (A)	1	145	24.77	<.0001
Tratamento (T)	2	145	21.51	<.0001
T*A	2	145	0.83	0.435
<hr/> $\beta_2$ <hr/>				
Ambiente (A)	1	145	10.07	0.002
Tratamento (T)	2	145	0.74	0.476
T*A	2	145	1.83	0.163
<hr/> $\beta_3$ <hr/>				
Ambiente (A)	1	145	21.82	<.0001
Tratamento (T)	2	145	1.58	0.2085
T*A	2	145	0.88	0.4166

Pinheiro & Bates (2000) citam que a adição de covariáveis pode ou não reduzir o número de efeitos aleatórios no modelo. Dessa forma podemos responder a seguinte pergunta: em qual aspecto do comportamento produtivo que as minhas covariáveis mais afetam? A resposta é a precocidade e a taxa de produção de frutos, representados pelos parâmetros  $\beta_2$  e  $\beta_3$ . O TRV mostrou que com a adição das covariáveis é possível excluir o efeito aleatório sobre parâmetros no modelo (Tabela 2).

Ressalta-se que a abordagem com modelos mistos permite ao pesquisador verificar de forma mais clara e objetiva como os efeitos de fatores testados em experimentos complexos afetariam o comportamento produtivo de olerícolas de múltiplas colheitas, o que seria dificultado se fossem utilizadas variáveis dummy's ou intervalos de confiança para os parâmetros.

**Tabela 2** – Teste de razão de verossimilhança para verificar a significância dos efeitos aleatórios de parcelas sobre os parâmetros de um modelo logístico.

Modelo	GL <sup>1</sup>	TRV	p-valor
Completo	25	-	-

$\beta_1$	22	46.334	<.0001
$\beta_2$	22	0.482	0.9228
$\beta_3$	22	0.000	1

<sup>1</sup>GL = graus de liberdade; TRV = teste de razão de verossimilhança.

#### 4 Conclusão

A utilização de modelos não lineares mistos é aconselhada em experimentos complexos, onde múltiplos fatores são testados concomitantemente.

Diferentes tratamentos interferem nas estimativas dos parâmetros do modelo não linear logístico. Entretanto a abordagem com modelos mistos permite que as conclusões sobre os efeitos dos tratamentos sobre a produção de tomateiro sejam mais claras e objetivas.

#### Referências Bibliográficas

- DIEL, M.I.; SARI, B.G.; KRYSCZUN, D.K.; OLIVOTO, T.; PINHEIRO, M.V.M.; MEIRA, D.; SCHMIDT, D.; LÚCIO, A.D. Nonlinear regression for description of strawberry (*Fragaria x ananassa*) production. **The Journal of Horticultural Science and Biotechnology**, vol. 94, n. 2, p. 259–273, 2019.
- PINHEIRO, J.C.; BATES, D.M. Mixed-Effects Models in S and S-Plus. New York: Springer. 2000, 528 p.
- R Core Team, 2018. R: A Language and Environment for Statistical Computing. R Foundation for Statistical Computing, Vienna, Austria.2018.URL <https://www.R-project.org/>.
- SARI, B.G.; OLIVOTO, T.; DIEL, M.I.; KRYSCZUN, D.K.; LÚCIO, A.D.; SAVIAN, T.V. Nonlinear Modeling for Analyzing Data from Multiple Harvest Crops. **Agronomy Journal**, v.110, n.6, p. 1–12, 2018.
- SARI, B.G.; LÚCIO, A.D.; SANTANA, C.S.; SAVIAN, T.V. Describing tomato plant production using growth models. **Scientia Horticulturae**, v.246, p. 146-154, 2019a.
- SARI, B.G.; LÚCIO, A.D.; SANTANA, C.S.; OLIVOTO, T.; DIEL, M.I.;KRYSCZUN, D.K. Nonlinear growth models: An alternative to ANOVA in tomato trials evaluation. **European Journal of Agronomy**, v.104, p. 21-36, 2019b.