

Modelagem espacial utilizando abordagem bayesiana para a incidência de Chikungunya no ano de 2016 para o estado do Rio de Janeiro usando o INLA

Lucas Monteiro Bianchi ¹, Leo Bastos ²

Introdução

A adaptação do processo evolutivo de arboviroses e o intenso desenvolvimento dos meios transporte à nível global têm favorecido com que a reemergência de arboviroses, fazendo-as com que alcancem regiões geograficamente mais distantes e de modo mais rápido. Arboviroses são doenças transmitidas pelo arbovírus (*Arthropod-borne virus*), sendo este, um tipo de vírus em que parte do seu ciclo ocorre nos insetos, podendo ser transmitidos aos seres humanos por picada de artrópodes hematófagos (LOPES; NOZAWA; LINHARES, 2014). A transmissão do arbovírus depende da combinação do mosquito e do genoma do vírus (CALVEZ et al., 2018). De acordo com Lopes, Nozawa e Linhares (2014), há mais de 545 arbovírus conhecidos, sendo que pelo menos 150 destes causam doenças aos seres humanos. Figueiredo (2015) afirma que pelo menos 9 arbovírus que transmitem doenças à humanos são encontrados no Brasil. O estado do Rio de Janeiro vem enfrentando sucessivas epidemias de arboviroses, como é o caso da Chikungunya, fazendo-se necessária o desenvolvimento de metodologias que consigam compreender a dinamicidade dessas doenças. Foram notificados 8.095 casos prováveis de chikungunya no estado no primeiro quadrimestre 2018, sendo que a maior parte dos casos estão concentrados na Região Metropolitana II (61,9%) e na Capital (27,9%), conforme divulgado no boletim epidemiológico arboviroses N^o 004/2018. A Chikungunya é transmitida por mosquitos do gênero *Aedes*, particularmente *Ae. aegypti* e *Ae. albopictus* e a infecção produz uma síndrome febril de início súbito e debilitante. Sob atuação da massa tropical atlântica e a presença de áreas remanescentes de florestas, o estado do Rio de Janeiro possui características que propiciam o desenvolvimento do vetor e consequentemente a prevalência da arbovirose. Penna (2003) diz que a população da cidade do Rio de Janeiro considera à proximidade com as florestas como um fator de constantemente preocupação no que se refere à propagação de arboviroses. Além disso, ações antrópicas, como migração populacional, ocupação desordenada de áreas urbanas sem os devidos cuidados quanto ao saneamento favorecem a dispersão do mosquito e a disseminação de vários sorotipos de doenças (LOPES; NOZAWA; LINHARES, 2014; RIBEIRO et al., 2006). Carvalho, Magalhães e Medronho (2017) realizaram um estudo da distribuição espacial da dengue para o estado do Rio de Janeiro considerando o período de 2001 a 2012 e constatou que a ocorrência da dengue está dispersa, entretanto verificou que os municípios com maiores números de notificações estão localizados nas regiões Baixadas Litorâneas e Norte Fluminense. Outros autores como Almeida, Medronho e Valencia (2009), consideraram como área de estudo o município do Rio de Janeiro e, sob uma ótica socioeconômica, observaram que os bairros localizados na zona oeste, devido principalmente à problemas de saneamento básico, apresentaram altas taxas de incidência média de dengue. Ainda considerando o município do Rio de Janeiro, na região de Leopoldina, Oliveira e Valla (2001) relataram que a falta de serviços regulares de abastecimento de água e de coleta

¹ENSP/Fiocruz-RJ. e-mail: lucas.bianchi123@hotmail.com

²PROCC/Fiocruz-RJ. e-mail: lsbastos.fiocruz@gmail.com

de lixo fazem com quem a população adote meios de reserva de água e destinação de lixo que acabavam criando condições favoráveis para a reprodução do vetor. As tentativas de reproduzir a realidade dos fenômenos espaciais geralmente são feitas por representações gráficas estáticas que muitas vezes não capturam e expressam as informações de modo adequado (DIAS; CÂMARA; JR, 2005). Em contrapartida, o rápido desenvolvimento de tecnologias computacionais e estatísticas criam um cenário propício para o emprego de modelos bayesianos que consideram a dependência espacial dos dados, algo complexo de se incorporar em modelos frequentistas. Um exemplo disso é a abordagem bayesiana para a estimativa de parâmetros pelo método INLA (*Integrated Nested Laplace Approximation*). Este método aproxima as distribuições a posteriori por meio de aproximações de Laplace via métodos computacionais determinísticos sem utilizar simulações, sendo ainda mais eficiente e mais rápido computacionalmente que o método de Monte Carlo via Cadeias de Markov (MCMC) que é tradicionalmente utilizado. Nesse sentido, este trabalho visa modelar a distribuição espacial dos casos de Chikungunya (CHIKV) e dessa forma, contribuir com uma metodologia para a identificação da realidade epidemiológica dessa arbovirose no estado do Rio de Janeiro.

1 Objetivos

Reconhecendo a importância do aprimoramento contínuo de metodologias para o monitoramento de doenças, este trabalho tem como objetivo a modelagem espacial estratificada por faixa etária e sexo da incidência de Chikungunya no Estado do Rio de Janeiro.

2 Área de estudo

O Estado do Rio de Janeiro possui uma população estimada de 17.159.960 habitantes, está localizado na região sudeste do país, abrange uma área de 43.780,172 km^2 e possui 92 municípios, sendo estes distribuídos em seis mesorregiões: Sul Fluminense, Metropolitana do Rio de Janeiro, Centro Fluminense, Baixadas Litorâneas, Norte Fluminense e Noroeste Fluminense.

3 Dados

Os dados de notificações de Chikungunya são referentes ao ano de 2016 e foram obtidos no Sistema de Informação de Agravos de Notificação (SINAN) enquanto os dados populacionais são de projeções do IBGE para o ano de 2015. Além disso, para evitar com que os números de casos notificados sejam mascarados pela discrepância populacional existente entre os municípios, os modelos consideram a incidência de casos notificados em cada município. Foi tratado como unidade de estudo a população pertencente à cada município e classificada como áreas vizinhas apenas as áreas de fronteiras, com exceção dos municípios Rio de Janeiro e Niterói que foram considerados como vizinhos devido à ponte Rio-Niterói que liga as duas cidades. Desse modo, é possível criar a chamada matriz de vizinhança, fundamental para o estudo espacial.

4 Metodologia

4.1 Estatística espacial

A Estatística espacial pode ser definida como uma coleção de técnicas que busca descrever os padrões existentes em que os dados são espacialmente localizados e se considera explicitamente a possível importância de seu arranjo espacial na análise ou interpretação dos resultados (BAILEY; GATRELL, 1995).

Os dados podem ser descritos como um processo estocástico indexado no espaço

$$Y(s) = \{y(s), s \in \mathcal{D}\} \quad (1)$$

onde \mathcal{D} é um subconjunto fixo de \mathbb{R}^d para d igual a 2. Os dados podem ser representados como uma coleção de observações $\mathbf{y} = \{y(s_1), \dots, y(s_n)\}$ onde o conjunto (s_1, \dots, s_n) corresponde a localização espacial da variável observada. Dependendo de \mathbb{R}^d , distribuição espacial da variável resposta pode ser dada de modo contínuo ou discreto. Neste projeto está sendo considerado como variável de interesse a contagem de notificações de Chikungunya Y_i em um município i , o que caracteriza como áreas com contagem. Para definir o modelo espacial utilizando abordagem bayesiana é necessário indentificar a distribuição de probabilidade da variável de interesse. Geralmente são utilizados distribuições pertencentes à família exponencial indexado à um parametro θ indicando a dependência espacial. A dependência espacial é considerada em termos de uma estrutura de vizinhança. Simplificando a notação anteriormente apresentada, ao invés de escrevermos (s_1, \dots, s_n) , passaremos a escrever $(1, \dots, n)$, assim temos um município i , seus vizinhos $\mathcal{N}(i)$ são os que fazem fronteira com o município i (vizinhos de 1^a ordem) ou os que fazem fronteiras com os vizinhos de primeira ordem (vizinhos de 2^a ordem), como ilustrado na figura 4.1.




Figura 1: Estrutura de vizinhança: vizinhos de 1^a ordem (esquerda), vizinhos de 2^a ordem (direita)

Fonte: (BLANGIARDO; CAMELETTI, 2015)

Sob as propriedades markovianas, o parâmetro θ_i para o i -ésimo município é independente de todos os outros parâmetros considerando a sua respectiva matriz de vizinhança $\mathcal{N}(i)$

(propriedade da Cadeia de Markov), então

$$\theta_i \perp\!\!\!\perp \boldsymbol{\theta}_{-\mathcal{N}(i)} | \boldsymbol{\theta}_{\mathcal{N}(i)} \quad (2)$$

onde θ_{-i} indica todos os elementos de $\boldsymbol{\theta}$ menos o i -ésimo, a matriz de precisão $\mathbf{Q} = \Sigma^{-1}$ é esparça (possui uma grande quantidade de valores nulos), produzindo uma grande vantagem computacional. Em outras palavras, qualquer par de elementos (i, j)

$$\theta_i \perp\!\!\!\perp \theta_j | \boldsymbol{\theta}_{-ij} \iff \mathbf{Q}(ij) = 0$$

sendo o padrão de valores não-nulos dado o pela estrutura de vizinhança do processo. Assim, $\mathbf{Q}(ij) \neq 0$ apenas se $j \in \{i, \mathcal{N}(i)\}$, conhecido como Campos Aleatórios Markovianos Gaussianos (CAMG) (RUE; HELD, 2005). Então, a independência de θ_i de θ_j não depende apenas só dos hiperparâmetros, mas também da estrutura de vizinhança. A matriz de precisão \mathbf{Q} pode ser expressa como a conhecida matriz de vizinhança \mathbf{R} :

$$\mathbf{Q} = \tau \mathbf{R}$$

onde,

$$R_{ij} = \begin{cases} \mathcal{N}(i), & \text{se } i = j \\ 1, & \text{se } i \sim j \\ 0, & \text{cc.} \end{cases} \quad (3)$$

4.2 Incidência (baseada em modelo)

Seja $Y_{s,a,m}$ o número de casos de Chikungunya para o sexo s , faixa etária a , e no município m de um determinado estado e para um período de tempo pré especificado, usualmente anual. Vamos supor que temos um modelo probabilístico M que nos permita inferir um valor para $Y_{s,a,m}$ que vamos denotar por $\tilde{Y}_{s,a,m}$. A incidência anual de Chikungunya no município m , para o sexo s e faixa etária a , denotada por $I_{s,a,m}$, é definida por

$$I_{s,a,m} = \frac{\tilde{Y}_{s,a,m}}{POP_{s,a,m}} \times 10^5,$$

onde $POP_{s,a,m}$ é o total de habitantes do município m do sexo s e faixa etária a . Diferentes escolhas para o modelo M implicará em diferentes valores para $\tilde{Y}_{s,a,m}$.

Incidência geral de Chikungunya no estado é dada por

$$I^{(estado)} = \frac{\sum_s \sum_a \sum_m I_{s,a,m} \times POP_{s,a,m}}{\sum_s \sum_a \sum_m POP_{s,a,m}}.$$

Note que a população do estado $POP^{(estado)} = \sum_s \sum_a \sum_m POP_{s,a,m}$ é o denominador da incidência do estado. E se o estimador de $\tilde{Y}_{s,a,m} = y_{s,a,m}$ então a incidência do estado se resume à incidência bruta, dada pelo total de casos no estado sobre a população do estado por 100 mil habitantes.

Incidência específica de Chikungunya por sexo é dada por

$$I_s^{(sexo)} = \frac{\sum_a \sum_m I_{s,a,m} \times POP_{s,a,m}}{\sum_a \sum_m POP_{s,a,m}}.$$

Incidência específica de Chikungunya por faixa etária é dada por

$$I_a^{(FaEt)} = \frac{\sum_s \sum_m I_{s,a,m} \times POP_{s,a,m}}{\sum_s \sum_m POP_{s,a,m}}.$$

Incidência específica de Chikungunya por faixa etária e sexo é dada por

$$I_{s,a}^{(SexoFaEt)} = \frac{\sum_m I_{s,a,m} \times POP_{s,a,m}}{\sum_m POP_{s,a,m}}.$$

Incidência específica de Chikungunya por município é dada por

$$I_m^{(mun)} = \frac{\sum_s \sum_a I_{s,a,m} \times POP_{s,a,m}}{\sum_s \sum_a POP_{s,a,m}}.$$

4.3 *Integrated Nested Laplace Approximation* - INLA

O uso de simulação de Monte Carlo via cadeias de Markov (MCMC) tem sido amplamente utilizada na inferência Bayesiana, principalmente quando é necessário estimar o valor integral de funções que não são analiticamente resolvíveis. Seu método consiste em realizar amostragens de uma cadeia de Markov estacionária que possui distribuição igual à distribuição a posteriori (BASTOS, 2018). Entretanto, ao considerar as dimensões do espaço e tempo, as estimações dos parâmetros pelo método MCMC se tornam algo computacionalmente ineficientes e podem produzir elevados valores para a estimativa dos erros dos parâmetros (KNORR-HELD, 2000). Rue, Martino e Chopin (2009) apresentaram um novo método que utiliza aproximações de Laplace para aproximar as distribuições a posteriori via métodos computacionais determinísticos, o *Integrated Nested Laplace Approximation* - INLA, cujo qual não utiliza simulações, ou seja, não é necessário verificar convergência, pois é um método determinístico. A grande vantagem deste método é que o tempo computacional é significativamente menor comparado com o tradicional método de MCMC (RUE; MARTINO, 2007). O INLA está implementado no R pelo pacote R-INLA. Contudo, o pacote R-INLA utiliza arquivos .ini e funções externas à biblioteca C e desta maneira não está disponível no CRAN, logo a sua instalação ocorre utilizando um repositório próprio do R-INLA *Project* através do seguinte código:

```
install.packages("INLA", repos=c(getOption("repos"),
  INLA="https://inla.r-inla-download.org/R/stable"), dep=TRUE)
```

4.4 Estimação Bayesiana com INLA

Na estatística muitas vezes se busca a estimação do efeito das covariáveis nos dados observados considerando ainda a correlação espacial e a espaço-temporal implícita no modelo. Isto geralmente é feito modelando a média da i -ésima observação pela média de um preditor linear aditivo definido adequadamente conforme com a variável de estudo.

$$\eta_i = \alpha + \sum_{m=1}^M \beta_m \mathbf{x} + \sum_{l=1}^L f_l Z_{li} \quad (4)$$

onde α é escalar e representa o intercepto, os coeficientes $\boldsymbol{\beta} = (\beta_1, \dots, \beta_M)$ quantificam os efeitos das covariáveis $\mathbf{x} = (x_1, \dots, x_M)$ na variável resposta, $\mathbf{f} = (f_1(\cdot), \dots, f_L(\cdot))$. Variando a forma da função $f_l(\cdot)$ é possível acomodar uma grande variedade de modelos,

incluído os modelos espaço-temporais (RUE; MARTINO; CHOPIN, 2009). Dado o modelo 4, seu vetor de parâmetros pode ser escrito como $\boldsymbol{\theta} = \{\alpha, \beta, \mathbf{f}\}$.

O objetivo do INLA é obter aproximações para as seguintes marginais a posteriori

$$p(\theta_i|\mathbf{y}) = \int p(\boldsymbol{\psi}|\mathbf{y})p(\theta_i|\boldsymbol{\psi}, \mathbf{y})d\boldsymbol{\psi}$$

e também para cada elemento do vetor de hiper-parâmetros

$$p(\psi_k|\mathbf{y}) = \int p(\boldsymbol{\psi}|\mathbf{y})d\boldsymbol{\psi}_{-\mathbf{k}}$$

onde $\boldsymbol{\psi} = (\psi_1, \dots, \psi_K)$ é o vetor de hiper-parâmetros. Como essas integrais geralmente são não resolvíveis, a solução é aproxima-las. Assim, é necessário obter:

1. $p(\boldsymbol{\psi}|\mathbf{y})$ para a qual todas as marginais $p(\psi_k|\mathbf{y})$ podem ser obtidas;
2. $p(\theta_i|\boldsymbol{\psi}, \mathbf{y})$ a qual é necessária para o cálculo da marginal posterior dos parâmetros.

4.5 Aproximação para $p(\boldsymbol{\psi}|\mathbf{y})$

Sabe-se que

$$p(\boldsymbol{\psi}|\mathbf{y}) = \frac{p(\boldsymbol{\theta}, \boldsymbol{\psi}|\mathbf{y})}{p(\boldsymbol{\theta}|\boldsymbol{\psi}, \mathbf{y})} \propto \frac{p(\boldsymbol{\psi})p(\boldsymbol{\theta}|\boldsymbol{\psi})p(\mathbf{y}|\boldsymbol{\theta})}{p(\boldsymbol{\theta}|\boldsymbol{\psi}, \mathbf{y})} \approx \frac{p(\boldsymbol{\psi})p(\boldsymbol{\theta}|\boldsymbol{\psi})p(\mathbf{y}|\boldsymbol{\theta})}{\tilde{p}(\boldsymbol{\theta}|\boldsymbol{\psi}, \mathbf{y})} \Big|_{\boldsymbol{\theta}=\boldsymbol{\theta}^*(\boldsymbol{\psi})}$$

onde $\tilde{p}(\boldsymbol{\theta}|\boldsymbol{\psi}, \mathbf{y})$ é a aproximação Gaussiana de $p(\boldsymbol{\theta}|\boldsymbol{\psi}, \mathbf{y})$ e $\boldsymbol{\theta}^*(\boldsymbol{\psi})$ é a sua moda (RUE; MARTINO; CHOPIN, 2009). Perceba que para cada valor de $\boldsymbol{\psi}$ teremos uma $\boldsymbol{\theta}^*(\boldsymbol{\psi})$.

4.6 Aproximação para $p(\theta_i|\boldsymbol{\psi}, \mathbf{y})$

Essa etapa geralmente é mais complexa devido ao $\boldsymbol{\theta}_i$ possuir mais elementos que $\boldsymbol{\psi}$ demandando mais tempo computacional. Uma das possibilidades de aproximar a distribuição posteriori condicional $p(\theta_i|\boldsymbol{\psi})$ diretamente como a marginal de $\tilde{p}(\boldsymbol{\theta}_i|\boldsymbol{\psi})$. Reescrevendo o vetor de parâmetros como $\boldsymbol{\theta}(\theta_i, \boldsymbol{\theta}_{-i})$ e usar novamente a aproximação de Laplace para obter:

$$p(\theta_i|\boldsymbol{\psi}, \mathbf{y}) = \frac{p((\theta_i, \boldsymbol{\theta}_{-i})|\boldsymbol{\psi}, \mathbf{y})}{p(\boldsymbol{\theta}_{-i}|\theta_i, \boldsymbol{\psi}, \mathbf{y})} \approx \frac{p(\boldsymbol{\theta}, \boldsymbol{\psi}|\mathbf{y})}{\tilde{p}(\boldsymbol{\theta}_{-i}|\theta_i, \boldsymbol{\psi}, \mathbf{y})} \Big|_{\boldsymbol{\theta}=\boldsymbol{\theta}_{-i}^*(\theta_i, \boldsymbol{\psi})} =: \tilde{p}(\theta_i|\boldsymbol{\psi}, \mathbf{y}) \quad (5)$$

onde $\tilde{p}(\boldsymbol{\theta}_{-i}|\theta_i, \boldsymbol{\psi}, \mathbf{y})$ é a aproximação Gaussiana de $p(\boldsymbol{\theta}_{-i}|\theta_i, \boldsymbol{\psi}, \mathbf{y})$ e $\boldsymbol{\theta}_{-i}^*(\theta_i, \boldsymbol{\psi})$ é a sua moda.

5 Resultados

5.1 Incidências de Chikungunya para RJ

As tabelas 1, 2 e 3 referem-se respectivamente à incidência geral, por sexo e por faixa etária. Destaca-se a diferença da incidência observada entre os sexos, entretanto, não há confirmações científicas para a explicação deste fenômeno, o que se há são teorias não comprovadas. Em estudos de incidência de Chikungunya, alguns autores encontraram resultados semelhantes quanto ao sexo visto ao encontrado neste estudo. Silva et al. (2018)

ao traçar o perfil epidemiológico para a incidência de Chikungunya no Brasil foi identificado que o sexo feminino é o que possui maior proporção de notificações ao ser comparado ao sexo masculino, embora, quanto a faixa etária, não foi observado maiores incidências nas faixas mais elevadas. Ribeiro, Sena e Almeida (2018) ao estudarem o perfil epidemiológico no estado da Bahia também observaram a predominância de notificações no sexo feminino, atribuindo a causa dessa diferença à possibilidade de que as mulheres procuram mais assistência médica devido a maior rotina diante dos aspectos sociohistóricos ainda existentes. Quanto à idade, as faixas etárias com maior média para a incidência foi a de 50 a 59 anos e 60 a 69 anos, respectivamente. O mesmo não foi observado pela Silva et al. (2018), a qual observou o predomínio da faixa etária de 20 a 39 anos (35,8%) nas notificações, seguidas pelas faixas etárias de 40-59 (29,7%) anos e indivíduos dos com menos de 19 anos de idade (21,7%).

Tabela 1: Incidência de Chikungunya.

Média	Qt. 0.025	Qt. 0.975	Qt. 0.165	Qt. 0.835
117.31	115.67	118.97	116.49	118.13

Tabela 2: Incidência de Chikungunya por sexo.

Sexo	Média	Qt. 0.025	Qt. 0.975	Qt. 0.165	Qt. 0.835
Fem.	146.64	144.08	149.22	145.36	147.92
Masc.	86.06	84.04	88.11	85.05	87.07

Tabela 3: Incidência de Chikungunya por faixa etária.

Faixa etária	Média	Qt. 0.025	Qt. 0.975	Qt. 0.165	Qt. 0.835
0 a 4 anos	14.68	12.47	17.17	13.57	15.90
05 a 9 anos	44.01	40.19	48.08	42.10	46.01
10 a 14 anos	62.48	58.11	67.08	60.30	64.75
15 a 19 anos	61.49	57.35	65.82	59.42	63.63
20 a 29 anos	97.28	93.49	101.18	95.39	99.21
30 a 39 anos	129.56	125.23	133.98	127.40	131.75
40 a 49 anos	159.94	154.82	165.18	157.39	162.54
50 a 59 anos	181.13	175.34	187.05	178.25	184.06
60 a 69 anos	178.67	171.69	185.85	175.19	182.22
70 a 79 anos	170.14	160.55	180.12	165.35	175.07
80 anos e mais	103.90	93.75	114.81	98.81	109.26

A figura 2 mostra a clara distinção entre os números de casos notificados de Chikungunya para homens e mulheres, sendo essa diferença significativa a partir da faixa dos 15 a 19 anos até a 70 a 79 anos.

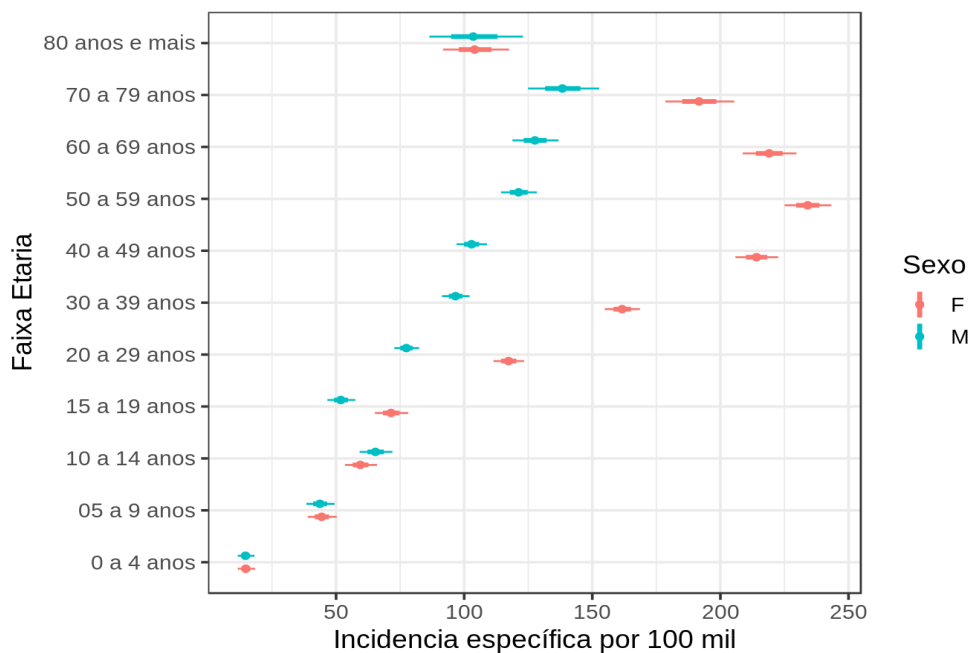


Figura 2: Incidência específica por sexo e faixa etária

O mapa abaixo (figura 3) mostra a distribuição espacial para a incidência de Chikungunya por município. Observa-se que a região metropolitana e a baixada litorânea são as regiões que englobam a maior quantidade de municípios com as mais elevadas incidências para o Estado, embora a região noroeste fluminense tenha o município com a maior incidência, Porciúncula.




Figura 3: Mapa da incidência específica de Chikungunya por município

5.2 Incidências ajustadas de Chikungunya para RJ

Seja o seguinte modelo:

$$Y_{s,a,m} \sim \text{Pois}(\lambda_{s,a,m})$$

onde

$$\log(\lambda_{s,a,m}) \sim 1 + s + a + s : a + \gamma_m + \text{offset}$$

na qual γ_m é um efeito aleatório espacial, ajustado segundo a soma de um processo CAR intrínseco e um processo gaussiano iid, conhecido por bym. O termo *offset* é dado por $\log(\text{POP}_{s,a,m} \times 10^{-5})$. Dessa forma, a incidência ajustada é dada pelo exponencial do preditor linear $\tilde{I}_{s,a,m} = e^{\eta_{s,a,m}}$ do modelo e a incerteza associada as estimativas de incidência geral e específicas é calculada via aproximação de Monte Carlo usando de amostras da posteriori aproximada do modelo completo via INLA.

Ao comparar os resultados obtidos, tabela 1 com a tabela 4, tabela 2 com a tabela 5 e tabela 3 com a tabela 6, os valores obtidos na modelagem se aproximam dos valores reais em todos os casos, havendo assim sobreposições do quantis (0.025 e 0.975) com os intervalos de credibilidade obtidos na modelagem.

Tabela 4: Incidência ajustadas de Chikungunya.

Média	LI	LS
117.63	115.96	119.31

Tabela 5: Incidência ajustadas de Chikungunya por sexo.

Sexo	Média	LI	LS
Fem.	147.05	144.43	149.74
Masc.	86.31	84.36	88.41

Tabela 6: Incidência ajustadas de Chikungunya por faixa etária.

Faixa etária	Média	LI	LS
0 a 4 anos	14.79	12.58	17.18
05 a 9 anos	44.18	40.56	48.45
10 a 14 anos	62.57	57.91	66.98
15 a 19 anos	61.64	57.72	65.84
20 a 29 anos	97.49	93.81	101.23
30 a 39 anos	129.94	125.52	134.21
40 a 49 anos	160.51	155.29	165.77
50 a 59 anos	181.70	176.30	187.84
60 a 69 anos	179.28	172.80	186.21
70 a 79 anos	170.49	161.21	180.74
80 anos e mais	103.88	93.98	114.99

É interessante observar que na única faixa etária (10 a 14 anos) que o sexo masculino apresenta incidência mais elevada, porém não significativa, que o sexo feminino, o modelo bayesiano foi capaz de captá-la.

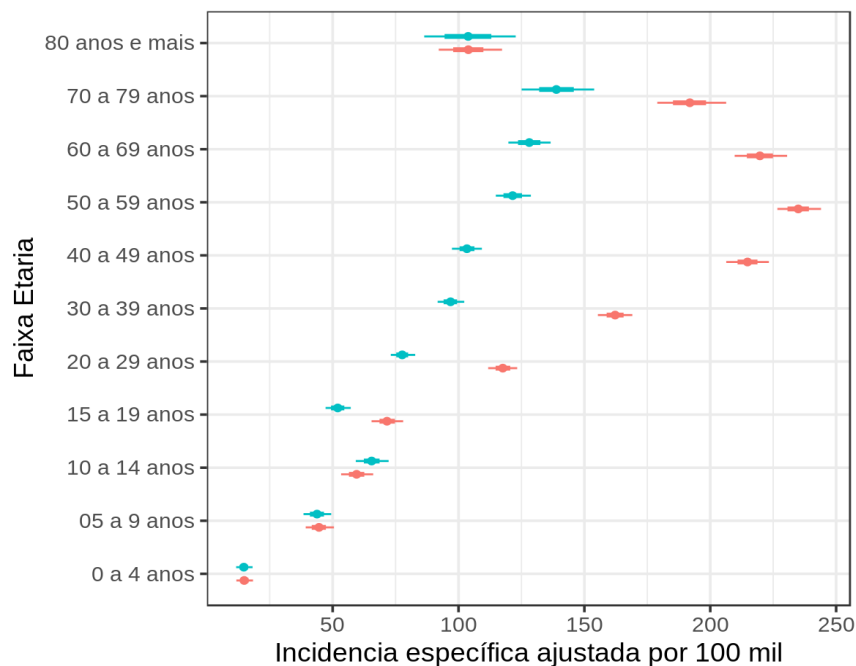


Figura 4: Incidência ajustada de Chikungunya por sexo e faixa etária

Ao considerar o componente espacial para a distribuição da incidência e as demais

variáveis (sexo e faixa etária), tem-se que o mapa gerado pela estimativas obtidas com a modelagem se equiparam às incidências obtidas apenas com os dados.

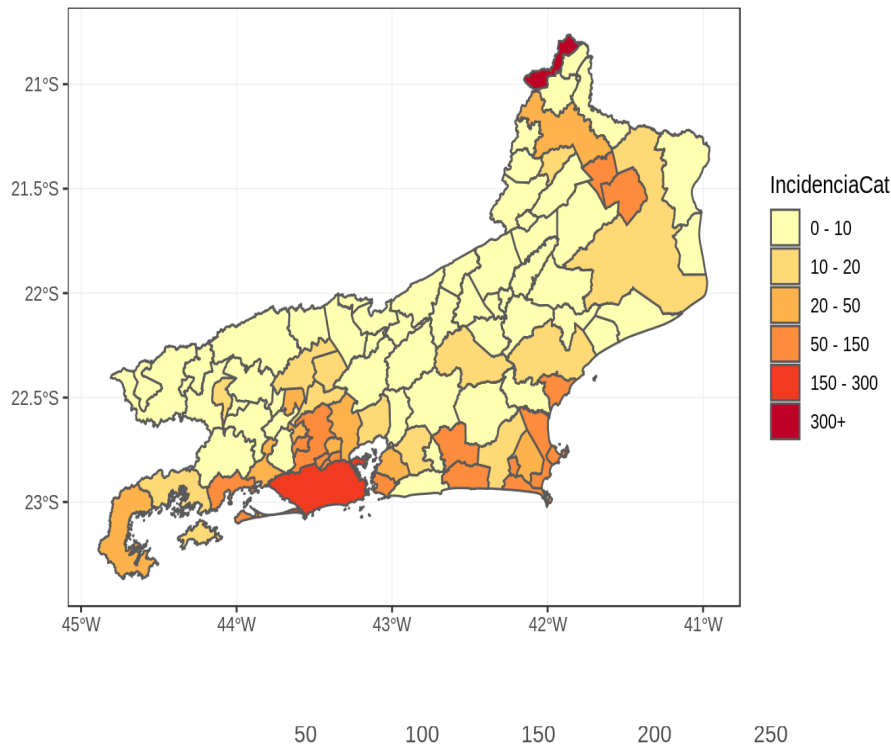


Figura 5: Mapa da incidência ajustada de Chikungunya por município

6 Conclusão

O conjunto de metodologias empregada permitiu identificar os municípios do estado do Rio de Janeiro que apresentavam maiores incidências para a ocorrência de Chikungunya. Desse modo, compreende-se que a modelagem espacial utilizando a abordagem bayesiana através do INLA é capaz de fornecer informações que podem resultar no auxílio de tomadas de decisões, podendo elencar áreas prioritárias mediante ao nível de incidência. Também foi possível observar o nível de incidência por sexo em cada faixa etária. Percebe-se que há mais casos notificados em mulheres, sendo essa diferença estatisticamente percebida a partir da faixa etária dos 15 aos 19 anos até a faixa dos 70 aos 90 anos. Entretanto, cabe investigações mais detalhadas por meio de contextos sociais para determinar as causas dessas diferenças.

Agradecimentos

Agradecimento à Capes pelo financiamento da bolsa de doutorado.

Referências

- ALMEIDA, A. S. d.; MEDRONHO, R. d. A.; VALENCIA, L. I. O. Spatial analysis of dengue and the socioeconomic context of the city of rio de janeiro (southeastern brazil). *Revista de saude publica*, SciELO Brasil, v. 43, n. 4, p. 666–673, 2009.
- BAILEY, T. C.; GATRELL, A. C. *Interactive spatial data analysis*. [S.l.]: Longman Scientific & Technical Essex, 1995. v. 413.
- BASTOS, M. M. *Modelagem probabilística da dinâmica da Zika usando modelos hierárquicos bayesianos*. Tese (Doutorado), 2018.
- BLANGIARDO, M.; CAMELETTI, M. *Spatial and spatio-temporal Bayesian models with R-INLA*. [S.l.]: John Wiley & Sons, 2015.
- CALVEZ, E. et al. Zika virus outbreak in the pacific: Vector competence of regional vectors. *PLoS neglected tropical diseases*, Public Library of Science, v. 12, n. 7, p. e0006637, 2018.
- CARVALHO, S.; MAGALHÃES, M. d. A. F. M.; MEDRONHO, R. d. A. Análise da distribuição espacial de casos da dengue no município do rio de janeiro, 2011 e 2012. *Rev. Saúde Pública*, SciELO Public Health, v. 51, 2017.
- DIAS, T. d. L.; CÂMARA, G.; JR, C. A. D. Modelos espaço-temporais. *MA Casanova, G Câmara, CA Davis Jr., L Vinhas, GR Queiroz.(Org. e Ed.). Bancos de Dados GeoGráficos. Editora Mundogeo, Curitiba, Cap*, v. 4, 2005.
- FIGUEIREDO, L. T. M. The recent arbovirus disease epidemic in brazil. *Revista da Sociedade Brasileira de Medicina Tropical*, SciELO Brasil, v. 48, n. 3, p. 233–234, 2015.
- KNORR-HELD, L. Bayesian modelling of inseparable space-time variation in disease risk. *Statistics in medicine*, Wiley Online Library, v. 19, n. 17-18, p. 2555–2567, 2000.
- LOPES, N.; NOZAWA, C.; LINHARES, R. E. C. Características gerais e epidemiologia dos arbovírus emergentes no brasil. *Revista Pan-Amazônica de Saúde*, v. 5, n. 3, p. 55–64, 2014.
- OLIVEIRA, R. M. d.; VALLA, V. V. As condições e as experiências de vida de grupos populares no rio de janeiro: repensando a mobilização popular no controle do dengue. *Cadernos de Saúde Pública*, SciELO Public Health, v. 17, p. S77–S88, 2001.
- PENNA, M. L. F. *Um desafio para a saúde pública brasileira: o controle do dengue*. [S.l.]: SciELO Public Health, 2003.
- RIBEIRO, A. F. et al. Associação entre incidência de dengue e variáveis climáticas. *Revista de Saúde Pública*, SciELO Public Health, v. 40, p. 671–676, 2006.
- RIBEIRO, I. B.; SENA, J. Costa da S.; ALMEIDA, H. L. Perfil epidemiológico da chikungunya no estado da bahia, brasil nos anos de 2014 a 2017. 2018.
- RUE, H.; HELD, L. *Gaussian Markov random fields: theory and applications*. [S.l.]: CRC press, 2005.

RUE, H.; MARTINO, S. Approximate bayesian inference for hierarchical gaussian markov random field models. *Journal of statistical planning and inference*, Elsevier, v. 137, n. 10, p. 3177–3192, 2007.

RUE, H.; MARTINO, S.; CHOPIN, N. Approximate bayesian inference for latent gaussian models by using integrated nested laplace approximations. *Journal of the royal statistical society: Series b (statistical methodology)*, Wiley Online Library, v. 71, n. 2, p. 319–392, 2009.

SILVA, N. M. d. et al. Vigilância de chikungunya no brasil: desafios no contexto da saúde pública. *Epidemiologia e Serviços de Saúde*, SciELO Public Health, v. 27, p. e2017127, 2018.