

A Distribuição Weibull na Modelagem de Dados de Tempo Até o Divórcio

Fabio Douglas Soares Bezerra¹, Daniel Valentins de Lima², Evandro Mariano Barros da Silva³, Marcelino Alves Rosa de Pascoa⁴, Graziela Dutra Rocha Gouvea⁵

Introdução

A distribuição de Weibull foi proposta originalmente por W. Weibull (1939) em estudos relacionados ao tempo de falha devido a fadiga de metais e, desde então, vem sendo frequentemente usada em estudos biomédicos e industriais. A sua popularidade em aplicações práticas deve-se ao fato dela apresentar uma grande variedade de formas, todas com uma propriedade básica: a sua função de taxa de falha é monótona, isto é, ela é estritamente crescente, estritamente decrescente ou constante (COLOSIMO; GIOLO, 2006).

Para uma variável aleatória T com distribuição Weibull tem-se a função de densidade de probabilidade, de sobrevivência e de risco dadas, respectivamente por

$$f(t) = \frac{\tau}{\alpha^\tau} t^{\tau-1} \exp \left[- \left(\frac{t}{\alpha} \right)^\tau \right],$$

$$S(t) = \exp \left[- \left(\frac{t}{\alpha} \right)^\tau \right]$$

e

$$h(t) = \frac{\tau}{\alpha} \left(\frac{t}{\alpha} \right)^{\tau-1},$$

em que $t > 0$, τ é o parâmetro de forma, e α o de escala, ambos positivos.

Objetivo

O objetivo deste trabalho foi através do método de máxima verossimilhança, estimar os parâmetros da distribuição de Weibull, utilizando dados de tempo de um casamento até o seu divórcio e comparar seu ajuste com o estimador de Kaplan-Meier.

¹ UFMT. email: *email.fabiodouglas.soares@gmail.com*

² UFMT. email: *email.dvalentins@outlook.com*

³ UFMT. email: *email.evandromarina_barros@live.com*

⁴ UFMT. email: *email.marcelino.pascoa@gmail.com*

⁵ UFOP. email: *email.gragouvea@gmail.com*

Metodologia

Os dados foram obtidos através da verificação dos registros de casamento realizados em um cartório, situado na Cidade de Cuiabá-MT. Foram avaliados 326 casamentos entre os anos de 2014 e 2018. Tendo como objeto de interesse o estudo do tempo até a ocorrência do divórcio.

Uma forma empírica de determinar o comportamento da função risco se da por meio da construção do gráfico do tempo total em teste (curva TTT), proposto por Aarset (1987). A curva TTT é obtida construindo um gráfico de

$$G\left(\frac{r}{n}\right) = \frac{\sum_{i=1}^r T_{i:n} + (n-r)T_{r:n}}{\sum_{i=1}^n T_{i:n}} \quad \text{por} \quad \frac{r}{n},$$

em que n é o tamanho da amostra, $r = 1, \dots, n$ e $T_{i:n}$, $i = 1, \dots, n$ são estatísticas de ordem da amostra.

A estimação dos parâmetros foi feita pelo método de máxima verossimilhança. Para que fosse possível realizar inferências fundamentadas no modelo, foi necessário obter a função de verossimilhança, logo considere uma amostra $X = (x_1, \dots, x_n)$ de n observações independentes, e seja F o conjunto do logaritmo dos tempos de vida e C o conjunto do logaritmo dos tempos de censura. Assim, o logaritmo da função de verossimilhança para o vetor de parâmetros $\theta = (\alpha, \tau)^T$ para o modelo (1) tem a forma $l(\theta) = \sum_{i \in F} l_i(\theta) + \sum_{i \in C} l_i^{(c)}(\theta)$, em que $l_i(\theta) = \log[f(x_i)]$, $l_i^{(c)}(\theta) = \log[S(x_i)]$, $f(x_i)$ é a função densidade de probabilidade (1) e $S(x_i)$ é a função de sobrevivência (2). Dessa forma, o logaritmo da função de verossimilhança para θ é

$$l(\theta) = r \log(\tau) - r \tau \log(\alpha) + (\tau - 1) \sum_{i \in F} t - \sum_{i \in F} \left(\frac{t}{\alpha}\right)^{\tau} - \sum_{i \in C} \left(\frac{t}{\alpha}\right)^{\tau}$$

Os componentes do vetor score $U = \left(\frac{\partial l}{\partial \alpha}, \frac{\partial l}{\partial \tau}\right)$ são obtidos por diferenciação de θ em relação aos parâmetros, logo

$$U_{\alpha}(\theta) = -\frac{r\tau}{\alpha} + \frac{\tau}{\alpha^{\tau+1}} \left(\sum_{i \in F} t^{\tau} + \sum_{i \in C} t^{\tau} \right)$$


$$U_{\tau}(\theta) = \frac{r}{\tau} - \sum_{i \in F} t - \sum_{i \in F} \log\left(\frac{t}{\alpha}\right) \left(\frac{t}{\alpha}\right)^{\tau} - \sum_{i \in C} \log\left(\frac{t}{\alpha}\right) \left(\frac{t}{\alpha}\right)^{\tau}$$

As estimativas dos parâmetros são soluções simultâneas das equações $U_{\alpha}(\theta) = 0$ e $U_{\tau}(\theta) = 0$. As análises foram implementadas no *software* estatístico R.

Resultados e discussões

A Curva TTT para o conjunto de dados de tempo até o divórcio encontra-se na Figura 1 e indica uma função risco na forma crescente. Assim, como a distribuição Weibull modela a função de risco na forma crescente ela é apropriada para analisar esse conjunto de dados.

Figura 1: Curva TTT para dados de divórcio.



Na Tabela 1, podem ser vistos as estimativas de máxima verossimilhança (e os correspondentes erros-padrão que estão entre parênteses) dos parâmetros e os valores das estatísticas dos modelos, Exponencial e Weibull. Os resultados indicam que o modelo Weibull tem os menores valores das estatísticas AIC (Critério de Informação de Akaike), BIC (Critério de Informação Bayesiano) e CAIC (Critério de Informação Akaike Consistente) entre os modelos ajustados, portanto, o modelo Weibull é o mais adequado para os dados de tempo de até o divórcio. O teste da razão de verossimilhança é apresentado na Tabela 2. Os resultados nessa tabela sugerem que o modelo Weibull produz um ajuste mais adequado a esses dados quando comparado com a distribuição exponencial.

Tabela 1: Ajuste final dos modelos comparados, para os dados de tempo até o divórcio

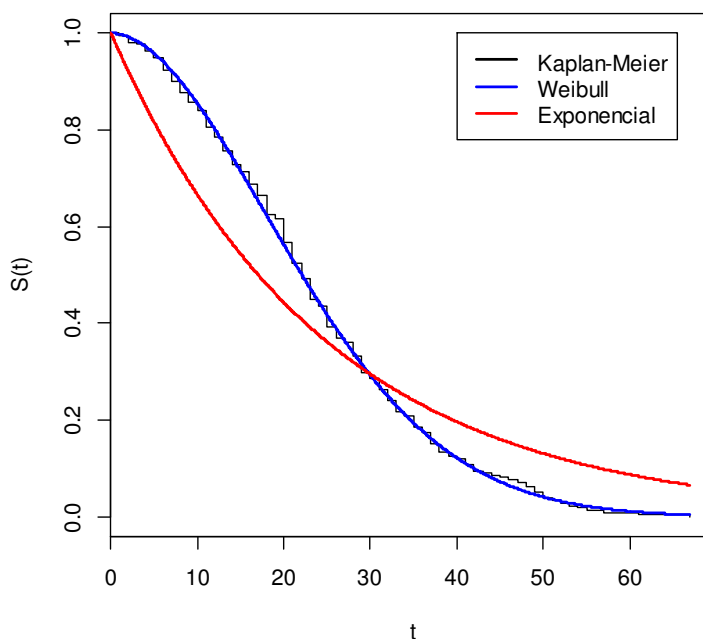
Modelo	α	τ	AIC	CAIC	BIC
Weibull	26,8656 (0,8564)	1,8720 (0,0842)	2405,3	2405,4	2412,8
Exponencial	24,5651 (1,4113)	1 (-)	2547,9	2548,0	2551,7

Tabela 2: Teste da razão de verossimilhança, para os dados de tempo até o divórcio

Modelo	Estatística do Teste	Valor p
Weibull vs Exponencial	144,6	< 0,0001

A Figura 2 apresenta a comparação das estimativas da função de sobrevivência segundo Kaplan-Meier e segundo os modelos Weibull e exponencial, para os dados de tempo até o divórcio. Observa-se pela figura que a distribuição Weibull nos fornece um ajuste satisfatório para os dados em estudo. Logo, conclui-se que os casais que não estão mais juntos se divorciam em média 24 meses após o casamento. Após 36 meses aproximadamente 83% dos casais que não estão mais juntos haviam se divorciado.

Figura 2: Estimativas da função de sobrevivência segundo Kaplan-Meier e segundo os modelos Weibull e Exponencial, para os dados de tempo até o divórcio



Conclusão

A distribuição Weibull proposta por Weibull (1954), apresentou melhor ajuste para os dados em estudo, segundo o teste da razão de verossimilhança e as estatísticas AIC, BIC e CAIC, quando comparada com a distribuição exponencial, se mostrando mais flexível.

Agradecimentos

Agradeço primeiramente a Deus e a minha esposa pela motivação a apreço ao estudo, bem como ao professor Marcelino e ao Cartório Xavier de Matos na pessoa da funcionária Eliza Santa que nos concedeu a oportunidade de realizar este trabalho.

Referencias Bibliográficas

AARSET, M. V. How to identify bathtub hazard rate. **Transaction son Reliability**. v. 36, p. 106-108, 1987.

COLOSIMO, E. A.; GIOLO, S.R., **Analise de Sobrevivência Aplicada**. Projeto Fisher – ABE. São Paulo: Edgard Blucher Ltda., 1^o Edição 89 p., 2006.

R CORE TEAM. R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. 2013. ISBN 3-900051-07-0, URL <http://www.R-project.org/>.

WEIBULL, W. A. A statistical theory of the strength of material. Royal Swedish Institute for Engineering Research, v. 151, p. 1–45, 1939.